

前沿论文研读清单（一）：检索与增强

L e w i s e t a l . , R e t r i e v a l - A u g m e n t e d
G e n e r a t i o n f o r K n o w l e d g e - I n t e n s i v e N L P
T a s k s , 2 0 2 0

提出

R A G：先用检索器召回文档片段，再让生成器基于片段作答，并证明检索能显著提升开放域问答的事实准确性。

R o b e r t s o n & Z a r a g o z a , T h e P r o b a b i l i s t i c
R e l e v a n c e F r a m e w o r k : B M 2 5 a n d B e y o n d , 2 0 0 9

系统阐述 O k a p i B M 2 5 的概率检索框架， k_1 与 b

参数分别控制词频饱和与长度归一化，是词法检索沿用至今的基线。

前沿论文研读清单（二）：注意力与大模型

Vaswani et al., Attention Is All You Need, 2017

提出缩放点积注意力与多头机制，除以根号 $\sqrt{d_k}$

防止点积方差过大；decoder-only 自回归架构成为后续大模型的主流选择。

Kaplan et al., Scaling Laws for Neural Language Models, 2020

损失随参数量、数据量、算力呈幂律下降，指导了算力分配：数据量提升往往比单纯放大模型更划算。

Ouyang et al., Training language models to follow instructions with human feedback, 2022

InstructGPT 论文，给出 SFT、奖励模型、PPO 的三段式对齐配方，是 RLHF 的经典范本，也是理解大模型对齐的第一篇必读。

前沿论文研读清单（三）：评测与可信

E s e t a l . , R A G A S : A u t o m a t e d E v a l u a t i o n o f
R e t r i e v a l A u g m e n t e d G e n e r a t i o n , 2 0 2 3

把 R A G 评测拆成忠实度、答案相关性与上下文相关性三个维度，用 L L M
作裁判自动化打分，主张指标分层报告而非只看端到端效果。

阅读方法：每篇论文按动机 - 方法 - 实验 - 局限四段式写笔记，并追问一个问题：这篇的方法如果
放在我的 R A G 项目里，消融实验会怎么设计？